

四、无约束最优化方法

4.1 梯度法（最速下降法）

4.2 牛顿法

4.2.1 基本牛顿法

推导：(在平板)

缺点

4.2.2 阻尼牛顿法

4.2.3 拟牛顿法

4.2.3.1 坐标变换

4.2.3.2 拟牛顿法(变尺度法)的基本原理

4.3 共轭梯度法

4.3.1 共轭方向定义及其性质

4.3.2 共轭梯度法求解二次函数最优解

四、无约束最优化方法

4.1 梯度法（最速下降法）

重点：函数沿梯度方向有最大变化率，证明见高等数学教材。（方向导数与梯度夹角）

步骤：

①选取初始点

②计算梯度

③求最优步长，即在当前梯度方向上一维搜索即可。范围：当前点到梯度方向的x1，x2即可，初始点选取当前点，进行一维搜索求出λ

④迭代直至满足条件。

$$X_{k+1} = X_k + \lambda_k P_k = X_k - \lambda_k \nabla f(X_k)$$

最速下降法应用于二次函数：

根据上述描述，二次函数表述为：

$$f(X) = \frac{1}{2}X^T QX + b^T X + C$$

求梯度，根据矩阵求导法则：

$$\frac{\partial \beta^T \mathbf{x}}{\partial \mathbf{x}} = \beta$$

$$\frac{\partial \mathbf{x}^T \mathbf{x}}{\partial \mathbf{x}} = 2\mathbf{x}$$

$$\frac{\partial \mathbf{x}^T \mathbf{A} \mathbf{x}}{\partial \mathbf{x}} = (\mathbf{A} + \mathbf{A}^T) \mathbf{x}$$

可以得到梯度公式：

$$\nabla f(\mathbf{X}) = \mathbf{Q}\mathbf{X} + \mathbf{b}$$

由单变量极值的必要条件：

$$\frac{df(\mathbf{X}_k + \lambda \mathbf{P}_k)}{d\lambda} = \nabla f(\mathbf{X}_{k+1})^T \mathbf{P}_k = 0$$

$k+1$ 点处梯度向量与前一次搜索方向正交。则为求出 λ ，计算 \mathbf{X}_{k+1} 处的梯度

$$\mathbf{g}_{k+1} = \mathbf{Q}\mathbf{X}_{k+1} + \mathbf{b} = \mathbf{Q}(\mathbf{X}_k + \lambda \mathbf{P}_k) + \mathbf{b} = \mathbf{g}_k + \lambda \mathbf{Q}\mathbf{P}_k$$

代入上式得：

$$\mathbf{g}_{k+1}^T \mathbf{P}_k = \mathbf{g}_k^T \mathbf{P}_k + \lambda \mathbf{P}_k^T \mathbf{Q} \mathbf{P}_k = 0$$

可求得 λ 的值：

$$\lambda_k = -\frac{\mathbf{g}_k^T \mathbf{P}_k}{\mathbf{P}_k^T \mathbf{Q} \mathbf{P}_k}$$

这样就可以按照公式一步一步迭代，非常方便。

4.2 牛顿法

4.2.1 基本牛顿法

直接用Hesse矩阵，但是对一些复杂函数很难求得Hesse矩阵（或者计算量极大）。

思路：泰勒展开二次函数，取其前三项，记为新函数 $m(\mathbf{X})$ ，根据极值条件， $m(\mathbf{X})$ 极小值处的梯度必为0，则可求得迭代关系：

$$\mathbf{X}_{k+1} = \mathbf{X}_k - \mathbf{G}(\mathbf{X}_k)^{-1} \mathbf{g}(\mathbf{X}_k)$$

其中， \mathbf{G} 为 $f(\mathbf{X})$ 的Hesse矩阵， $\mathbf{g}(\mathbf{X})$ 为 $f(\mathbf{X})$ 的梯度。

推导：(在平板)

缺点

1. Hessian矩阵的逆可能非常难求解。
2. 对于一般的非线性函数，牛顿法可能不能始终保持函数的下降性。

4.2.2 阻尼牛顿法

基本牛顿法的基础上引入步长因子和一维搜索加以解决，即令：

$$\begin{aligned} K^k &= -H^{-1}(K^k)J(X^k) \\ \min f(X^k + \alpha S^k) &\rightarrow a_k \\ X^{k+1} &= X^k + \alpha_k S^k \end{aligned}$$

详细过程与框图如下：

牛顿法的迭代步骤如下：

- ① 给定初始点 X^0 和收敛精度 $\varepsilon > 0$ ，置 $k=0$ 。
- ② 计算函数在点 X^k 上的梯度、二阶导数矩阵及其逆矩阵。
- ③ 构造搜索方向

$$S^k = -[\nabla^2 f(X^k)]^{-1} \nabla f(X^k)$$

- ④ 沿方向 S^k 一维搜索，得到阻尼因子 α_k 和新的迭代点

$$X^{k+1} = X^k + \alpha_k S^k$$

- ⑤ 收敛判断：若 $\|\nabla f(X^{k+1})\| \leq \varepsilon$ ，则令最优解为 $X^* = X^{k+1}$ 和 $f(X^*) = f(X^{k+1})$ ，终止计算；否则，令 $k=k+1$ ，转②继续迭代。

牛顿法的程序框图见图 4-5。

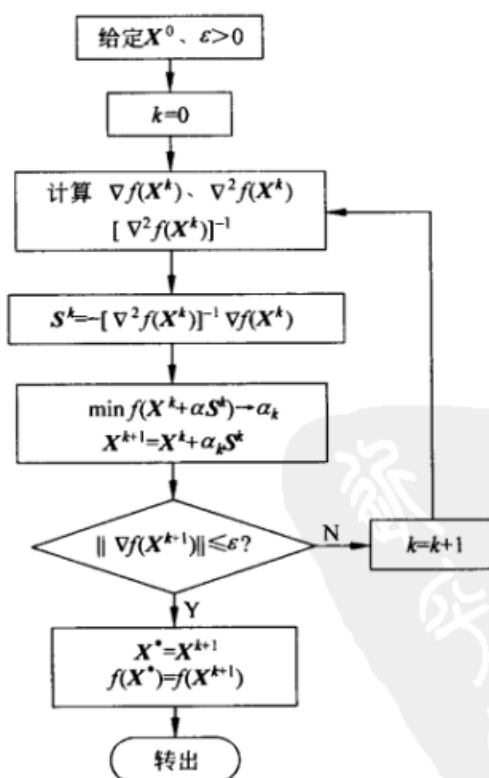


图 4-5 牛顿法的程序框图

4.2.3 拟牛顿法

不需要计算海瑟矩阵就可以通过逐步递推的方式逼近牛顿方向。

4.2.3.1 坐标变换

4.2.3.2 拟牛顿法(变尺度法)的基本原理

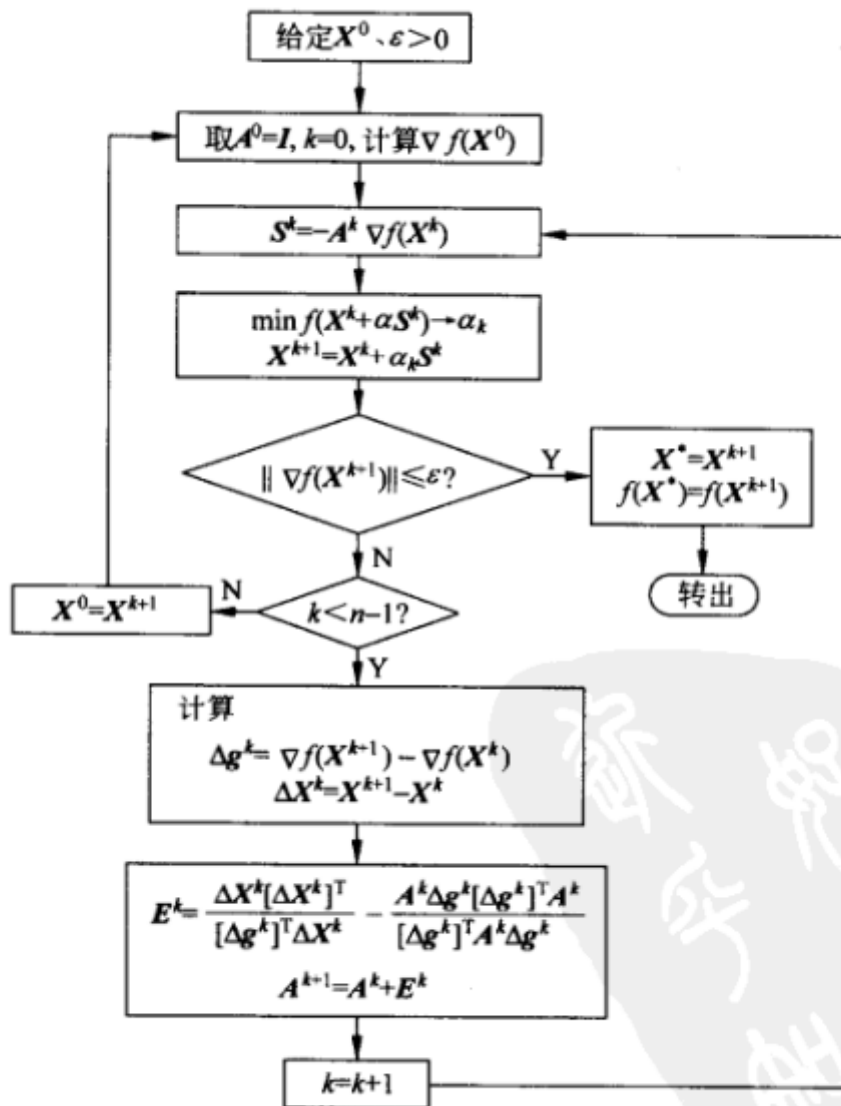


图 4-7 变尺度法的程序框图

4.3 共轭梯度法

介绍：共轭梯度法克服了最速下降法的锯齿现象；从而既提高了收敛速度，又避免了牛顿法中有关 Hesse 矩阵的计算，非常厉害。

思想：虽然梯度下降法的每一步都是朝着局部最优的方向前进的，但是它在不同的迭代轮数中会选择非常近似的方向，说明这个方向的误差并没通过一次更新方向和步长更新完，在这个方向上还存在误差，因此参数更新的轨迹是锯齿状。共轭梯度法的思想是，选择一个优化方向后，本次选择的步长能够将这个方向的误差更新完，在以后的优化更新过程中不再需要朝这个方向更新了。由于每次将一个方向优化到了极小，后面的优化过程将不再影响之前优化方向上的极小值，所以理论上对 N 维问题求极小只用对 N 个方向都求出极小就行了。

4.3.1 共轭方向定义及其性质

定义：共轭方向：设 Q 是 n 阶对称正定矩阵，若向量组 p_1, p_2, \dots, p_m 满足

$$p_i^T Q p_j \begin{cases} = 0, i \neq j \\ \neq 0, i = j \end{cases}$$

则称该向量组 P 共轭(Q 正交)

可见，当 $Q=I$ 时，上式就是通常的正交条件

定理：共轭方向性质：设向量组P对于对称正定矩阵Q共轭，则向量组P线性无关。

定理：共轭梯度法：设向量组P对于对称正定矩阵Q共轭，则从任意一点X1出发，依次经过p1, p2, ..., pn为搜索方向的下属算法，经n次一维搜索收敛于二次函数的最优解X

$$\begin{cases} \min f(X_k + \lambda p_k) = f(X_k + \lambda_k p_k) \\ X_{k+1} = X_k + \lambda_k p_k \end{cases}$$

现在推导其求解二次函数的迭代公式。

4.3.2 共轭梯度法求解二次函数最优解

先从初始点取该点负梯度方向为搜索方向，做一维搜索得到X2。从新点求搜索方向，根据共轭条件即可。

步骤：

①初始点X1，以初始方向P1=-g1，一维搜索得到X2

$$X_2 = X_1 + \lambda_1 P_1$$

②计算第二个方向P2，通过共轭条件可解出

取第二个方向：

$$P_2 = -g_2 + \beta_1 P_1$$

共轭条件：

$$P_2^T Q P_1 = (-g_2 + \beta_1 P_1)^T Q P_1 = 0$$

解出β1

$$\beta_1 = \frac{g_2^T Q P_1}{P_1^T Q P_1}$$

③确定了P2后，从X2按照P2方向一维搜索得到λ2

$$X_3 = X_2 + \lambda_2 P_2$$

④重复上述步骤n次(二次函数2次即可)

