

Linear-Gaussian Estimation

- 3.1 Batch Discrete-Time Estimation
 - 3.1.1 Problem Setup
 - 状态估计目的
 - 状态估计问题
 - 3.1.2 Maximum A Posteriori
 - 解此无约束最优化问题：
 - 形象化
 - 3.1.3 贝叶斯推断
 - 提升形式推导：
 - 3.1.4 Existence, Uniqueness and Observability
 - case1 Knowledge of initial state
 - case2 No knowledge of initial state
 - 3.1.5 MAP的协方差
- 3.2 Recursive Discrete-Time Smoothing
 - 3.2.1 Exploiting Sparsity in the Batch Solution
 - 3.2.2 Cholesky Smoother
 - 3.2.3 Rauch-Tung-Striebel 平滑算法
- 3.3 离散时间的递归滤波算法
 - 3.3.1 Factoring the Batch Solution
 - 3.3.2 通过MAP推导卡尔曼滤波
 - 3.3.3 通过贝叶斯推断推导卡尔曼滤波
 - 3.3.4 从增益最优化的角度来看卡尔曼滤波
 - 3.3.5 关于卡尔曼滤波的讨论
 - 3.3.6 误差动态过程
 - 3.3.7 存在性，唯一性以及能观性
- 3.4 连续时间的批量估计问题
 - 3.4.1 高斯过程回归
 - 3.4.2 一种稀疏的高斯过程先验
 - 3.4.3 线性时不变情况
 - 3.4.4 与批量离散时间情况的关系

Linear-Gaussian Estimation

Words	Translate
recursive	递归的
deterministic	决定性的
sparse	稀疏的
exploit	利用

3.1 Batch Discrete-Time Estimation

译作：离散时间的批量估计

3.1.1 Problem Setup

这章节的大部分内容，我们考虑**离散时间、线性、时变的方程**。我们定义如下的运动以及观测模型：

$$\begin{aligned} \text{motion model} : x_k &= A_{k-1}x_{k-1} + v_k + w_k, \quad k = 1 \dots K \\ \text{observation model} : y_k &= C_k x_k + n_k, \quad k = 0 \dots K \end{aligned}$$

其中，k是离散时间下标，最大值为K。上述符号意义如下：

$$\begin{aligned} \text{system state} : \mathbf{x}_k &\in \mathbb{R}^N \\ \text{initial state} : \mathbf{x}_0 &\in \mathbb{R}^N \sim \mathcal{N}(\check{\mathbf{x}}_0, \check{\mathbf{P}}_0) \\ \text{input} : \mathbf{v}_k &\in \mathbb{R}^N \\ \text{process noise} : \mathbf{w}_k &\in \mathbb{R}^N \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_k) \\ \text{measurement} : \mathbf{y}_k &\in \mathbb{R}^M \\ \text{measurement noise} : \mathbf{n}_k &\in \mathbb{R}^M \sim \mathcal{N}(\mathbf{0}, \mathbf{R}_k) \end{aligned}$$

除了 v_k 以外，这些都是随机变量。**噪声和初始状态我们均假设各不相关，而且不同时刻也不相关**。矩阵 A_k 称为**转移矩阵(transition matrix)**，矩阵 $C_k \in \mathbb{R}^{(M \times N)}$ 被称为**观测矩阵(observation matrix)**。

状态估计目的

我们的首要目的：估计(得到)系统的所有时间的所有状态。

我们的已知：

1. 初始状态 x_0 以及其协方差矩阵 P_0 ；我们有时候不知道初始信息，就需要在不知道的情况下进行推导。
2. 输入 v_k ，来自我们的控制器输出，已知，而且其噪声协方差矩阵 Q_k 。
3. 测量值 y_k, meas ，是 y_k 的一次**实现**，噪声协方差： R_k

状态估计问题

状态估计问题是指：在k个(一个或多个)时间点上，基于初始的状态信息 x_0 、一系列观测数据 $y(0:K, \text{meas})$ 、一系列输入 $v(1:K)$ ，以及系统的运动和观测模型，来计算系统的真实状态的估计值 $x(k)$ 。

我们回到LG(Linear Gaussian)系统的估计问题：我们用两个不同的途径解决此问题：

1. **贝叶斯推断(Bayesian inference)**：我们从状态的先验概率密度函数出发，通过初始状态、输入、运动方程和观测数据，计算状态的后验概率密度函数。
2. **最大后验估计(Maximum A Posteriori MAP)**：我们用优化理论，来寻找给定信息下(初始状态、输入、观测)的最大后验估计。

3.1.2 Maximum A Posteriori

译作：最大后验估计

在批量估计问题中，我们的目标是解决如下MAP问题：

$$\hat{x} = \operatorname{argmax}_x p(x|v, y)$$

我们希望在给定先验信息和所有时刻的运动 v 、观测 y 的情况下，推测出所有时刻的最优状态 \hat{x} 。

为此，我们定义一些数据：**我们用上帽子表示后验估计(包含了观测量的)，用下帽子表示先验估计(不含观测的)**

$$\begin{aligned}x &= x_{0:K} = (x_0, \dots, x_K) \\v &= (\check{x}_0, v_1, \dots, v_K) \\y &= y_{0:K} = (y_0, \dots, y_K)\end{aligned}$$

我们首先利用贝叶斯公式重写MAP：过程详解

$$\hat{x} = \operatorname{argmax}_x p(x|v, y) = \operatorname{argmax}_x \frac{p(y|x, v)p(x|v)}{p(y|v)} = \operatorname{argmax}_x p(y|x)p(x|v)$$

$$\begin{aligned}p(x|v, y) &= (\text{贝叶斯公式}) \frac{p(v, y|x)p(x)}{p(v, y)} \\&= (\text{条件概率公式}) \frac{p(v, y|x)p(x)}{p(y|v)p(v)} \\&= (\text{条件概率公式}) \frac{p(v, y, x)}{p(y|v)p(v)} \\&= (\text{条件概率公式}) \frac{p(y|x, v)p(x, v)}{p(y|v) \frac{p(x, v)}{p(x|v)}} \\&(\text{化简}) = \frac{p(y|x, v)p(x|v)}{p(y|v)}\end{aligned}$$

最后一个等式的解释：分母 $p(y|v)$ 与变量 x 无关，可以当作常数；分子中， $p(y|x, v)$ 的 v 可以省略，因为如果 x 已知， v 不会影响观测数据(观测方程与其无关)。

接下来，我们做出一个重要假设：噪声 w_k 和 n_k 之间无关。这样我们有：

$$p(y|x) = \prod_{k=0}^K p(y_k|x_k) (\text{根据观测方程可以得到})$$

另一方面，贝叶斯定理允许我们将 $p(x|v)$ 分解为：

$$\begin{aligned}p(x|v) &= p(x_0|\check{x}_0) \prod_{k=1}^K p(x_k|x_{k-1}, v_k) \\&(\text{根据输入方程可得})\end{aligned}$$

线性系统中，高斯密度函数可展开为：

$$\begin{aligned}p(x_0|\check{x}_0) &= \frac{1}{\sqrt{(2\pi)^N \det(\check{P}_0)}} \times \exp(-\frac{1}{2}(x_0 - \check{x}_0)\check{P}_0^{-1}(x_0 - \check{x}_0)) \\p(x_k|x_{k-1}, v_k) &= (\text{根据运动方程}) \frac{1}{\sqrt{\dots}} \\p(y_k|x_k) &= (\text{根据观测方程}) \frac{1}{\sqrt{\dots}}\end{aligned}$$

我们对优化的式子取对数(由于对数函数是**单调递增的(monotonically increasing)**，因此对我们的优化问题没有影响)。

$$\ln(p(y|x)p(x|v)) = \ln(p(x_0|\check{x}_0)) + \sum_{k=1}^K \ln p(x_k|x_{k-1}, v_k) + \sum_{k=0}^K \ln p(y_k|x_k)$$

将上式代入，并且拿掉与 x 无关的常数项，我们定义：

$$J_{v,k}(x) = \begin{cases} \frac{1}{2}(x_0 - \check{x}_0)^T \check{P}_0^{-1}(x_0 - \check{x}_0) & , \quad k = 0 \\ \frac{1}{2}(x_k - A_{k-1}x_{k-1} - v_k)^T Q_k^{-1}(x_k - A_{k-1}x_{k-1} - v_k) & , \quad k = 1 \dots K \end{cases}$$

$$J_{y,k}(x) = \frac{1}{2}(y_k - C_k x_k)^T R_k^{-1}(y_k - C_k x_k) \quad , \quad k = 0 \dots K$$

这些都是平方马氏距离(Mahalanobis distances)。我们对整体定义**目标函数(objective function)**, 寻找最小值

$$J(x) = \sum_{k=0}^K (J_{v,k}(x) + J_{y,k}(x))$$

我们还可以对J函数进行修改(添加限制或者惩罚项), 这些看情况而定。

综上所述, **我们把最大后验估计搞成了求Jx的最小值的问题**。也是无约束最优化问题。

$$\hat{x} = \operatorname{argmin}_x J(x)$$

解此无约束最优化问题:

我们想办法把函数搞成x的平方的形式:

我们令所有已知量为z, 所有待估计量为x:

$$z = [\check{x}_0, v_1, \dots, v_K, y_0, \dots, y_K]^T$$

$$x = [x_0, \dots, x_K]^T$$

我们定义以下块矩阵: ? ? ? ? ? ? ? ? ? ?

$$H = \begin{bmatrix} 1 & & & & & \\ -A_0 & 1 & & & & \\ & \ddots & \ddots & & & \\ & & -A_{K-1} & 1 & & \\ C_0 & & & & & \\ & C_1 & & & & \\ & & \ddots & & & \\ & & & C_K & & \end{bmatrix},$$

$$W = \left[\begin{array}{ccc|ccc} \check{P}_0 & & & & & \\ & Q_1 & & & & \\ & & \ddots & & & \\ & & & Q_K & & \\ \hline & & & & R_0 & \\ & & & & & R_1 \\ & & & & & \ddots \\ & & & & & & R_K \end{array} \right],$$

我们可以得到:

$$J(x) = \frac{1}{2}(z - Hx)^T W^{-1}(z - Hx)$$

同时，我们也有：

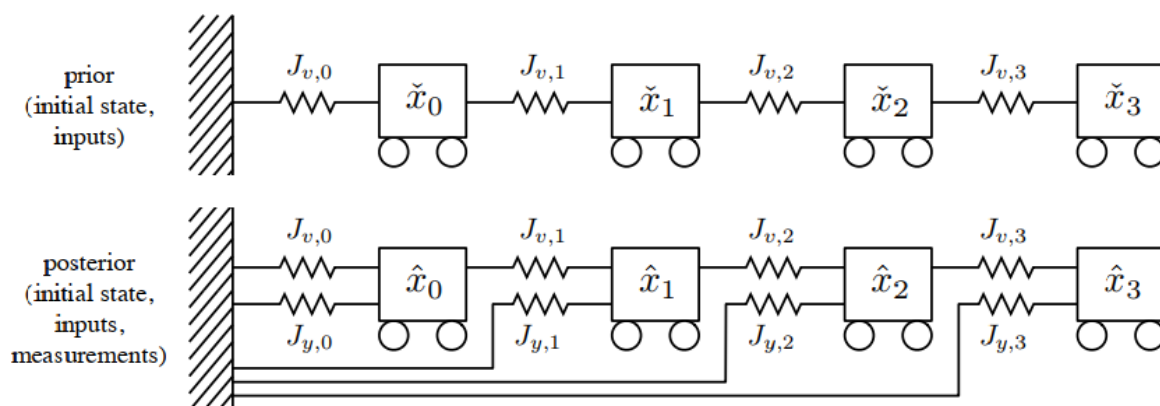
$$p(z|x) = \eta \exp(-\frac{1}{2}(z - Hx)^T W^{-1}(z - Hx))$$

η 为归一化常数。此时，我们对 $J(x)$ 求导数：

$$\begin{aligned} \frac{dJ(x)}{dx} &= -H^T W^{-1}(z - H\hat{x}) = 0 \\ (H^T W^{-1} H)\hat{x} &= H^T W^{-1} z \end{aligned}$$

不过这个求逆不需要硬求，可以利用矩阵的稀疏性，后续会讲解。

形象化



如图所示，批量估计问题的一个直观解释。函数的每一项可以认为是弹簧中储存的能量，根据运动方程可以得到先验，其中先验与上一个状态有关；而测量量直接与状态量相关，这样我们使系统能量最小即可得到后验估计。

3.1.3 贝叶斯推断

我们已经见到通过优化方法来进行批量线性高斯估计的方法，我们现在来通过贝叶斯法则，而不是最大化后验。**我们要从先验的概率密度出发，然后再用测量的数据来更新它。**

单独的 k 时刻方程，统一写成矩阵形式

先验：通过初始值和输入构建先验估计，利用运动方程得到：

$$x_k = A_{k-1}x_{k-1} + v_k + w_k$$

在**提升形式**下：我们有

$$x = A(v + w)$$

其中 w 是初始状态和运动噪声的提升形式：

$$A = \begin{bmatrix} \mathbf{1} & & & & \\ \mathbf{A}_0 & \mathbf{1} & & & \\ \mathbf{A}_1 \mathbf{A}_0 & \mathbf{A}_1 & \mathbf{1} & & \\ \vdots & \vdots & \vdots & \ddots & \\ \mathbf{A}_{K-2} \cdots \mathbf{A}_0 & \mathbf{A}_{K-2} \cdots \mathbf{A}_1 & \mathbf{A}_{K-2} \cdots \mathbf{A}_2 & \cdots & \mathbf{1} \\ \mathbf{A}_{K-1} \cdots \mathbf{A}_0 & \mathbf{A}_{K-1} \cdots \mathbf{A}_1 & \mathbf{A}_{K-1} \cdots \mathbf{A}_2 & \cdots & \mathbf{A}_{K-1} & \mathbf{1} \end{bmatrix}$$

提升形式推导：

我们注意：我们也要估计 x_0 ，且输入 $v_0=x_0$ 已知，(x_0 先验(观测方程)= x_0 已知+ w_k 噪声)

我们得到：

$$\begin{aligned}x_0 &= \check{x}_0 + w_0 \\x_1 &= A_0 x_0 + v_1 + w_1 \\&\dots \\x_k &= A_{k-1} x_{k-1} + v_k + w_k\end{aligned}$$

由于每一项都有 $v+w$ 的部分，因此，**A矩阵的对角线上全为1**。其次，根据递推，上式的值代入下式总能得到规律，因此我们易得A矩阵的形式。

提升形式下，均值：（噪声 w 的均值为0）

$$\check{x} = E[x] = E[A(v + w)] = Av$$

协方差：

$$\begin{aligned}\check{P} &= E[(x - E[x])(x - E[x])^T] \\&= E[(A(v + w) - Av)(A(v + w) - Av)^T] \\&= E[Aww^T A^T] (A \text{ 为已知常数矩阵}) \\&= AQA^T\end{aligned}$$

其中，(Q 为每次噪声的方差)

$$Q = E[ww^T] = \text{diag}(\check{P}_0, Q_1, \dots, Q_K)$$

先验可以表示为：这么写的原因是运动方程， v 的条件下 x 的值， $p(x|v)$

$$p(x|v) = N(\check{x}, \check{P}) = N(Av, AQA^T)$$

继续，测量模型：

$$y_k = C_k x_k + n_k$$

我们要写成 $y=Cx+n$ 的形式，接下来求 C 。

$$C = \text{diag}(C_0, C_1, \dots, C_K)$$

综上，我们有：

$$p(\mathbf{x}, \mathbf{y}|\mathbf{v}) = \mathcal{N}\left(\begin{bmatrix} \check{\mathbf{x}} \\ \mathbf{C}\check{\mathbf{x}} \end{bmatrix}, \begin{bmatrix} \check{\mathbf{P}} & \check{\mathbf{P}}\mathbf{C}^T \\ \mathbf{C}\check{\mathbf{P}} & \mathbf{C}\check{\mathbf{P}}\mathbf{C}^T + \mathbf{R} \end{bmatrix}\right),$$

其中

$$\mathbf{R} = E[nn^T] = \text{diag}(R_0, R_1, \dots, R_k)$$

我们对上式进行推导：

均值比较好理解，现在看一下协方差矩阵：

$$\begin{aligned}
p(y|v) &= N(C\check{x}, \check{P}_y) \\
\check{P}_y &= E[(y - E(y))(y - E(y))^T] \\
&= E[(Cx + n - C\check{x})(Cx + n - C\check{x})^T] \\
&= E[(CAw + n)(CAw + n)^T] \\
&= (n_k \text{之间相互独立, 均值为零}) E[CAww^T A^T C^T] + E[nn^T] \\
&= C\check{P}C^T + R \\
E[(x - E(x))(y - E(y))] &= E[Aw(CAw + n)^T] \\
&= E[Aww^T A^T C^T] + E[n^T] \\
&= \check{P}C^T
\end{aligned}$$

我们可以进行因式分解：

$$\begin{aligned}
p(x, y|v) & \text{(条件概率公式)} \\
&= \frac{p(x, y, v)}{p(v)} \\
&= \frac{p(x, y, v)}{p(y, v)} \frac{p(y, v)}{p(v)} \\
&= p(x|v, y)p(y|v)
\end{aligned}$$

我们只关心 $p(x|v, y)$ ，这是全贝叶斯后验概率，观测 y 输入 v 的条件下， x 的概率分布。

我们用(2.2.3)节的方法，写成：(2.2.3推导)

$$p(\mathbf{x}|\mathbf{v}, \mathbf{y}) = \mathcal{N}\left(\check{\mathbf{x}} + \check{\mathbf{P}}\mathbf{C}^T(\mathbf{C}\check{\mathbf{P}}\mathbf{C}^T + \mathbf{R})^{-1}(\mathbf{y} - \mathbf{C}\check{\mathbf{x}}), \check{\mathbf{P}} - \check{\mathbf{P}}\mathbf{C}^T(\mathbf{C}\check{\mathbf{P}}\mathbf{C}^T + \mathbf{R})^{-1}\mathbf{C}\check{\mathbf{P}}\right). \quad (3.28)$$

附带上式推导：由2.2.3节中得到：

利用式子(2.75)中的SMW恒等式，可以将上式转换为：

$$p(\mathbf{x}|\mathbf{v}, \mathbf{y}) = \mathcal{N}\left(\underbrace{(\check{\mathbf{P}}^{-1} + \mathbf{C}^T \mathbf{R}^{-1} \mathbf{C})^{-1} (\check{\mathbf{P}}^{-1} \check{\mathbf{x}} + \mathbf{C}^T \mathbf{R}^{-1} \mathbf{y})}_{\text{即均值 } \hat{\mathbf{x}}}, \underbrace{(\check{\mathbf{P}}^{-1} + \mathbf{C}^T \mathbf{R}^{-1} \mathbf{C})^{-1}}_{\text{即后验协方差 } \hat{\mathbf{P}}}\right)$$

附带公式：

我们为了便于优化，整理以下上式的均值项：

$$\underbrace{(\check{\mathbf{P}}^{-1} + \mathbf{C}^T \mathbf{R}^{-1} \mathbf{C})}_{\hat{\mathbf{P}}^{-1}} \hat{\mathbf{x}} = \check{\mathbf{P}}^{-1} \check{\mathbf{x}} + \mathbf{C}^T \mathbf{R}^{-1} \mathbf{y}$$

我们代入：

$$\begin{aligned}
\check{\mathbf{x}} &= \mathbf{A}v \\
\check{\mathbf{P}}^{-1} &= (\mathbf{A} \mathbf{Q} \mathbf{A}^T)^{-1} = \mathbf{A}^{-T} \mathbf{Q}^{-1} \mathbf{A}^{-1}
\end{aligned}$$

可以得到：

$$\underbrace{(A^{-T}Q^{-1}A^{-1} + C^TR^{-1}C)}_{\hat{P}^{-1}} \hat{x} = A^{-T}Q^{-1}v + C^TR^{-1}y$$

这里需要计算A的逆，不过，A的逆有一个很好看的形式：?????

$$A^{-1} = \begin{bmatrix} 1 & & & & & \\ -A_0 & 1 & & & & \\ & -A_1 & 1 & & & \\ & & -A_2 & \ddots & & \\ & & & \ddots & 1 & \\ & & & & -A_{K-1} & 1 \end{bmatrix},$$

我们定义：

$$\begin{aligned} z &= [v \ y]^T \\ H &= [A^{-1} \ C]^T \\ W &= \begin{bmatrix} Q & \\ & R \end{bmatrix} \end{aligned}$$

我们就可以把系统写成：

$$(H^TW^{-1}H)\hat{x} = H^TW^{-1}z$$

3.1.4 Existence, Uniqueness and Observability

译作：存在性，唯一性，能观性

我们看线性高斯系统估计中有且仅有唯一解的情况：当且仅当 $H^TW^{-1}H$ 可逆。有：

$$\begin{aligned} \hat{x} &= (H^TW^{-1}H)^{-1}H^TW^{-1}z \\ \text{rank}(H^TW^{-1}H) &= N(K+1) \end{aligned}$$

由于W的逆为实对称正定矩阵，那么我们有：

$$\text{rank}(H^TH) = \text{rank}(H^T) = N(K+1)$$

我们现在有两种情况：

1. 我们有良好的初始先验 x_0
2. 我们没有良好的初始先验

case1 Knowledge of initial state

我们直接看 H^TH 即可：

$$\text{rank } H^T = \text{rank} \left[\begin{array}{cccc|cccc} 1 & -A_0^T & & & C_0^T & & & \\ & 1 & -A_1^T & & & C_1^T & & \\ & & 1 & \ddots & & & C_2^T & \\ & & & \ddots & -A_{K-1}^T & & \ddots & \\ & & & & 1 & & & C_K^T \end{array} \right]$$

很明显，矩阵满秩，因此，我们能够得到唯一解 \hat{x} ，只需要：

$$\begin{aligned} \ddot{P}_0 &> 0 \\ Q_k &> 0 (\text{正定}) \end{aligned}$$

case2 No knowledge of initial state

没有良好的初始先验值，我们就只能去掉 H^T 的第一列，变为：

$$\text{rank } H^T = \text{rank} \left[\begin{array}{cccc|cccc} -A_0^T & & & & C_0^T & & & \\ 1 & -A_1^T & & & & C_1^T & & \\ & 1 & \ddots & & & & C_2^T & \\ & & \ddots & -A_{K-1}^T & & \ddots & & \\ & & & 1 & & & & C_K^T \end{array} \right]$$

这个矩阵有 $K+1$ 行，每块大小为 N ，将最上一行移到最下，得到：

$$\text{rank } H^T = \text{rank} \left[\begin{array}{cccc|cccc} 1 & -A_1^T & & & & C_1^T & & \\ & 1 & \ddots & & & & C_2^T & \\ & & \ddots & -A_{K-1}^T & & \ddots & & \\ & & & 1 & & & & C_K^T \\ -A_0^T & & & & C_0^T & & & \end{array} \right]$$

我们为了将其变为阶梯型，我们用 A_0^T 乘最后一行，然后加到最后一行上；再用 $A_0^T A_1^T$ 乘第二行，加到最后一行上，。。。。。。得到

$$\text{rank } H^T = \text{rank} \left[\begin{array}{cccc|cccc} 1 & -A_1^T & & & C_1^T & & & \\ & 1 & \ddots & & & C_2^T & & \\ & & \ddots & -A_{K-1}^T & & \ddots & & \\ & & & 1 & & & & C_K^T \\ \hline & & & & C_0^T & A_0^T C_1^T & A_0^T A_1^T C_2^T & \dots A_0^T \dots A_{K-1}^T C_K^T \end{array} \right]$$

那么，我们只需要右下角的分块矩阵的秩为N即可，即：

$$\text{rank} \begin{bmatrix} C_0^T & A_0^T C_1^T & A_0^T A_1^T C_2^T & \dots & A_0^T \dots A_{K-1}^T C_K^T \end{bmatrix} = N$$

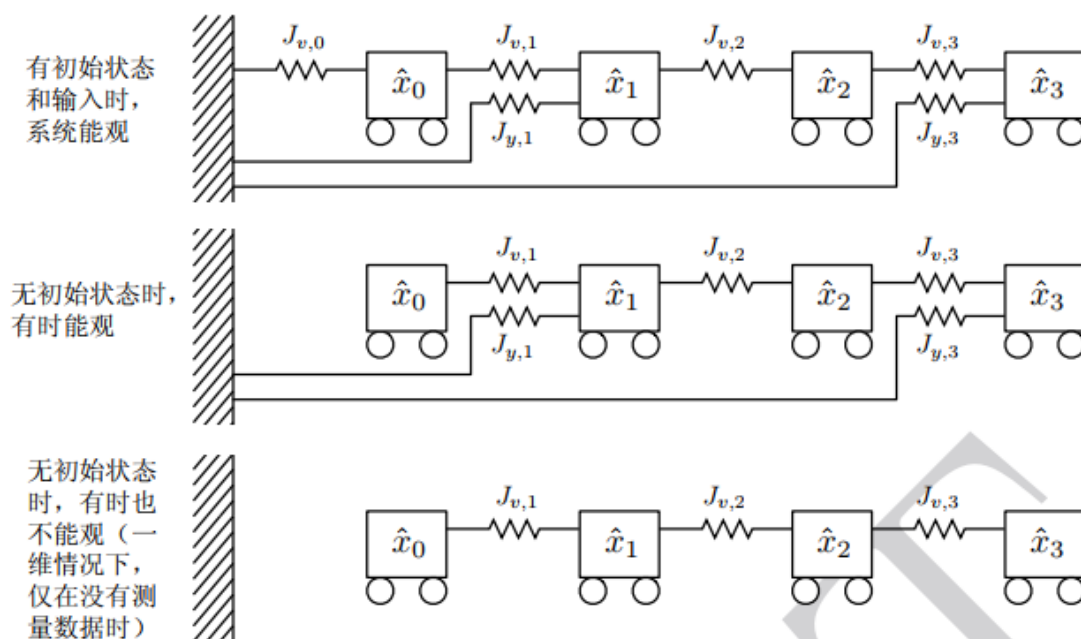
根据克莱哈密顿定理，我们直接给出结论：

式(3.3.4)的解存在且唯一的条件是：

$$O = \begin{bmatrix} C \\ CA \\ \dots \\ CA^{N-1} \end{bmatrix}$$

$$Q_k > 0, R_k > 0, \text{rank}(O) = N$$

我们用弹簧模型来解释一下：如图所示



1. 当我们有初始状态时，系统总是能观的(无法移动任意一个(或多个)重物而不改变至少一个弹簧的长度)，这时候有一个唯一的最小能量状态。
2. 中间例子，就算不知道初始状态，也是能观的，有唯一解。
3. 最后一个就不行了，没有初始状态，也没有观测值，没有唯一解。

3.1.5 MAP的协方差

xhat代表x状态的最有估计，但是这个xhat有多少置信度？

3.2 Recursive Discrete-Time Smoothing

译作：离散时间的递归平滑算法

概述：离散时间的批量估计中，给出了良好的结论，也容易从最小二乘的角度来理解？？？？？思考。但是，蛮力去解线性方程组是非常低效的。幸运的是，因为左侧的协方差矩阵的逆具有稀疏结构(对角块)，我们可以用这个性质有效地求解。

$$(H^T W^{-1} H) \hat{x} = H^T W^{-1} z$$

3.2.1 Exploiting Sparsity in the Batch Solution

译作：利用稀疏性求解批量估计

如之前所讨论，我们有如下结论：

$$\mathbf{H}^T \mathbf{W}^{-1} \mathbf{H} = \begin{bmatrix} * & * & & & \\ * & * & * & & \\ & * & * & * & \\ & & \ddots & \ddots & \ddots \\ & & & * & * & * \\ & & & & * & * \end{bmatrix},$$

其中，*代表非零块。可以采取稀疏**Cholesky分解**进行求解。Cholesky分解详见数值分析课程。

我们可以将上述矩阵分解为：

$$\mathbf{H}^T \mathbf{W}^{-1} \mathbf{H} = \mathbf{L} \mathbf{L}^T$$

由于等式左侧为三对角块，因此L的形式如下：?????

$$\mathbf{L} = \begin{bmatrix} * & & & & \\ * & * & & & \\ & * & * & & \\ & & \ddots & \ddots & \ddots \\ & & & * & * \\ & & & & * & * \end{bmatrix}$$

然后，先解：

$$\mathbf{L} \mathbf{d} = \mathbf{H}^T \mathbf{W}^{-1} \mathbf{z}$$

再解：

$$\mathbf{L}^T \hat{\mathbf{x}} = \mathbf{d}$$

3.2.2 Cholesky Smoother

译作：Cholesky 平滑算法

我们看一下L的形式：

$$L = \begin{bmatrix} L_0 & & & & & \\ L_{10} & L_1 & & & & \\ & L_{21} & L_2 & & & \\ & & \ddots & \ddots & & \\ & & & L_{K-1,K-2} & L_{K-1} & \\ & & & & L_{K,K-1} & L_K \end{bmatrix} \quad (3.60)$$

我们展开并对比(这与矩阵的Cholesky分解过程较为类似)，一个位置一个位置的矩阵块对应相等即可，我们得到：

$$L_0 L_0^T = \underbrace{\check{P}_0^{-1} + C_0^T R_0^{-1} C_0}_{I_0} + A_0^T Q_1^{-1} A_0 \quad (3.61a)$$

$$L_{10} L_0^T = -Q_1^{-1} A_0 \quad (3.61b)$$

$$L_1 L_1^T = \underbrace{-L_{10} L_{10}^T + Q_1^{-1} + C_1^T R_1^{-1} C_1}_{I_1} + A_1^T Q_2^{-1} A_1 \quad (3.61c)$$

$$L_{21} L_1^T = -Q_2^{-1} A_1 \quad (3.61d)$$

\vdots

$$L_{K-1} L_{K-1}^T = \underbrace{-L_{K-1,K-2} L_{K-1,K-2}^T + Q_{K-1}^{-1} + C_{K-1}^T R_{K-1}^{-1} C_{K-1}}_{I_{K-1}} + A_{K-1}^T Q_K^{-1} A_{K-1} \quad (3.61e)$$

$$L_{K,K-1} L_{K-1}^T = -Q_K^{-1} A_{K-1} \quad (3.61f)$$

$$L_K L_K^T = \underbrace{-L_{K,K-1} L_{K,K-1}^T + Q_K^{-1} + C_K^T R_K^{-1} C_K}_{I_K} \quad (3.61g)$$

如上所示，式子中我们标出了一些中间变量 I_k 。从这些式子可以看出，我们先解 L_0 (一步小型块稠密矩阵的分解)，然后将结果代入2式中得到 L_{10} ，从上往下依次求解。

接下来，我们从来解 d ：(方法与上类似)

$$Ld = H^T W^{-1} z$$

展开得到：

$$L_0 d_0 = \underbrace{\check{P}_0^{-1} \tilde{x}_0 + C_0^T R_0^{-1} y_0}_{q_0} - A_0^T Q_1^{-1} v_1$$

$$L_1 d_1 = \underbrace{-L_{10} d_0 + Q_1^{-1} v_1 + C_1^T R_1^{-1} y_1}_{q_1} - A_1^T Q_2^{-1} v_2$$

\vdots

$$L_{K-1} d_{K-1} = \underbrace{-L_{K-1,K-2} d_{K-2} + Q_{K-1}^{-1} v_{K-1} + C_{K-1}^T R_{K-1}^{-1} y_{K-1}}_{q_{K-1}} - A_{K-1}^T Q_K^{-1} v_K$$

$$L_K d_K = \underbrace{-L_{K,K-1} d_{K-1} + Q_K^{-1} v_K + C_K^T R_K^{-1} y_K}_{q_K}$$

最后，我们来解 \hat{x} ：

$$L^T \hat{x} = d$$

展开块矩阵运算，得到：

$$\begin{aligned}
L_K^T \hat{x}_K &= d_K \\
L_{K-1}^T \hat{x}_{K-1} &= -L_{K,K-1}^T \hat{x}_K + d_{K-1} \\
&\vdots \\
L_1^T \hat{x}_1 &= -L_{21}^T \hat{x}_2 + d_1 \\
L_0^T \hat{x}_0 &= -L_{10}^T \hat{x}_1 + d_0
\end{aligned}$$

这样，我们就解完了。我们综合一下，整理得到：

对于中间量 I_k 和 q_k ，我们能够综合前向与后向两步（即解 L 和 d 的过程），将它们写成：

前向： $k = 1 \dots K$

$$L_{k-1} L_{k-1}^T = I_{k-1} + A_{k-1}^T Q_k^{-1} A_{k-1} \quad (3.66a)$$

$$L_{k-1} d_{k-1} = q_{k-1} - A_{k-1}^T Q_k^{-1} v_k \quad (3.66b)$$

$$L_{k,k-1} L_{k-1}^T = -Q_k^{-1} A_{k-1} \quad (3.66c)$$

$$I_k = -L_{k,k-1} L_{k-1}^T + Q_k^{-1} + C_k^T R_k^{-1} C_k \quad (3.66d)$$

$$q_k = -L_{k,k-1} d_{k-1} + Q_k^{-1} v_k + C_k^T R_k^{-1} y_k \quad (3.66e)$$

后向： $k = K \dots 1$

$$L_{k-1}^T \hat{x}_{k-1} = -L_{k,k-1}^T \hat{x}_k + d_{k-1} \quad (3.66f)$$

这些量的初始值为：

$$I_0 = \check{P}_0^{-1} + C_0^T R_0^{-1} C_0 \quad (3.67a)$$

$$q_0 = \check{P}_0^{-1} \check{x}_0 + C_0^T R_0^{-1} y_0 \quad (3.67b)$$

$$\hat{x}_K = L_K^{-T} d_K \quad (3.67c)$$

3.2.3 Rauch-Tung-Striebel 平滑算法

我们求解上式3.66c中的 $L(k,k-1)$ ，这需要式子a, b的结果。解完后将结果代入3.66d中得到 I_k ：

令：

$$\begin{aligned}
\hat{P}_{k,f} &= I_k^{-1} \\
\check{P}_{k,f} &= (A_{k-1} I_{k-1}^{-1} + Q_k)^{-1}
\end{aligned}$$

我们将上式写成：

$$\begin{aligned}
\check{P}_{k,f} &= (A_{k-1} I_{k-1}^{-1} + Q_k)^{-1} \\
\hat{P}_{k,f} &= \check{P}_{k,f}^{-1} + C_k^T R_k^{-1} C_k
\end{aligned}$$

这里，第一个式子表示预测的协方差，通过输入方程。而第二个式子表示修正的协方差，通过观测方程。

我们用卡尔曼增益 K_k 来表示：定义

$$\begin{aligned}
K_k &= \hat{P}_{k,f} C_k^T R_k^{-1} \\
&\text{经过推导： (P54)} \\
\hat{P}_{k,f} &= (1 - K_k C_k) \check{P}_{k,f}
\end{aligned}$$

综上所述，式 (3.69a)，式 (3.71)，式 (3.76a)，式 (3.78)，式 (3.81) 构成了 Rauch-Tung-Striebel 平滑算法：

前向： $k = 1 \dots K$

$$\tilde{P}_{k,f} = A_{k-1} \hat{P}_{k-1,f} A_{k-1}^T + Q_k \quad (3.82a)$$

$$\tilde{x}_{k,f} = A_{k-1} \hat{x}_{k-1,f} + v_k \quad (3.82b)$$

$$K_k = \tilde{P}_{k,f} C_k^T (C_k \tilde{P}_{k,f} C_k^T + R_k)^{-1} \quad (3.82c)$$

$$\hat{P}_{k,f} = (1 - K_k C_k) \tilde{P}_{k,f} \quad (3.82d)$$

$$\hat{x}_{k,f} = \tilde{x}_{k,f} + K_k (y_k - C_k \tilde{x}_{k,f}) \quad (3.82e)$$

后向： $k = K \dots 1$

$$\hat{x}_{k-1} = \hat{x}_{k-1,f} + \hat{P}_{k-1,f} A_{k-1}^T \tilde{P}_{k,f}^{-1} (\hat{x}_k - \tilde{x}_{k,f}) \quad (3.82f)$$

它们的初始值为：

$$\tilde{P}_{0,f} = \tilde{P}_0 \quad (3.83a)$$

$$\tilde{x}_{0,f} = \tilde{x}_0 \quad (3.83b)$$

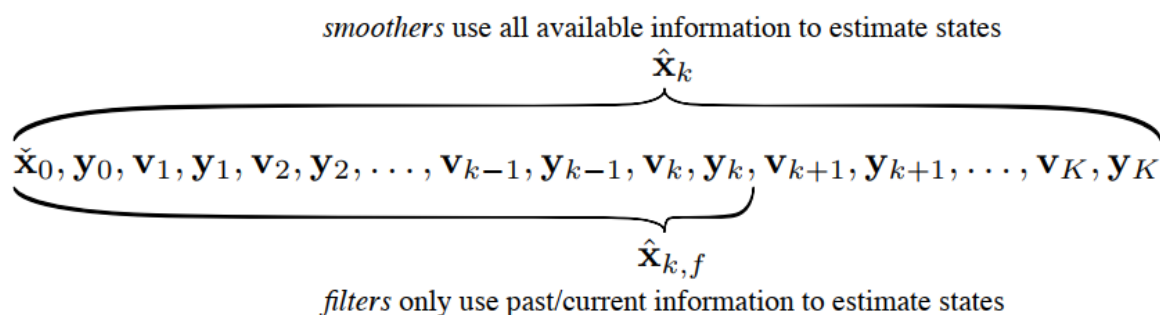
$$\hat{x}_K = \hat{x}_{K,f} \quad (3.83c)$$

前向的五个过程被称为卡尔曼滤波器，这六个公式表达的式RTS平滑算法。这件事情成立的原因，正式由于优化算法左侧矩阵的特殊三对角块的稀疏结构。

3.3 离散时间的递归滤波算法

本章其余部分，介绍其他几种推导和理解卡尔曼滤波器的方法。

这张图体现了批量估计算法和滤波器估计(卡尔曼滤波)的区别。



3.3.1 Factoring the Batch Solution

为了把结论写成递归的形式，我们重新排列一下批量优化中的变量，重新定义z、H、W(只是交换了矩阵行的位置)。

$$\mathbf{z} = \begin{bmatrix} \check{\mathbf{x}}_0 \\ \mathbf{y}_0 \\ \mathbf{v}_1 \\ \mathbf{y}_1 \\ \mathbf{v}_2 \\ \mathbf{y}_2 \\ \vdots \\ \mathbf{v}_K \\ \mathbf{y}_K \end{bmatrix}, \quad \mathbf{H} = \begin{bmatrix} 1 & & & & \\ \mathbf{C}_0 & & & & \\ \hline -\mathbf{A}_0 & 1 & & & \\ & \mathbf{C}_1 & & & \\ \hline & -\mathbf{A}_1 & 1 & & \\ & & \mathbf{C}_2 & & \\ \hline & & \ddots & \ddots & \\ & & & -\mathbf{A}_{K-1} & 1 \\ & & & & \mathbf{C}_K \end{bmatrix},$$

$$\mathbf{W} = \begin{bmatrix} \check{\mathbf{P}}_0 & & & & \\ & \mathbf{R}_0 & & & \\ \hline & & \mathbf{Q}_1 & & \\ & & & \mathbf{R}_1 & \\ \hline & & & & \mathbf{Q}_2 \\ & & & & & \mathbf{R}_2 \\ \hline & & & & & \ddots \\ & & & & & & \mathbf{Q}_K \\ & & & & & & & \mathbf{R}_K \end{bmatrix}, \quad (3.84)$$

如上式，这些线分开了不同时间戳的变量。

现在，我们来考虑其在概率密度函数层面的分解(factorization)。我们现在想考虑k时刻的状态，**我们进行边缘化操作，把其他时刻的变量积分出去**

$$p(x_k | v, y) = \int_{x_i, \forall i \neq k} p(x_i | v, y) dx_i, \forall i \neq k$$

为了实现分解，我们要用到H的稀疏结构。先把H分解成12个块(仅有6个非零块)。如下所示：

$$\mathbf{H} = \begin{bmatrix} \mathbf{H}_{11} & & & \\ \mathbf{H}_{21} & \mathbf{H}_{22} & & \\ & \mathbf{H}_{32} & \mathbf{H}_{33} & \\ & & \mathbf{H}_{43} & \end{bmatrix} \begin{array}{l} \text{information from } 0 \dots k-1 \\ \text{information from } k \\ \text{information from } k+1 \\ \text{information from } k+2 \dots K \end{array}$$

\uparrow
states from $0 \dots k-1$

\uparrow
states from k

\uparrow
states from $k+1 \dots K$

举个k=2, K=4的例子：

$$\mathbf{H} = \begin{bmatrix} 1 & & & & \\ \mathbf{C}_0 & & & & \\ -\mathbf{A}_0 & 1 & & & \\ & \mathbf{C}_1 & & & \\ & -\mathbf{A}_1 & 1 & & \\ & & \mathbf{C}_2 & & \\ & & -\mathbf{A}_2 & 1 & \\ & & & \mathbf{C}_3 & \\ & & & -\mathbf{A}_3 & 1 \\ & & & & \mathbf{C}_4 \end{bmatrix}. \quad (3.88)$$

我们把z和W也转换成这个样式：

$$\mathbf{z} = \begin{bmatrix} \mathbf{z}_1 \\ \mathbf{z}_2 \\ \mathbf{z}_3 \\ \mathbf{z}_4 \end{bmatrix}, \quad \mathbf{W} = \begin{bmatrix} \mathbf{W}_1 & & & \\ & \mathbf{W}_2 & & \\ & & \mathbf{W}_3 & \\ & & & \mathbf{W}_4 \end{bmatrix}. \quad (3.89)$$

那么，具体的矩阵 $\mathbf{H}^T \mathbf{W}^{-1} \mathbf{H}$ 计算为：

其中， L_{ij} 为中间变量。

同样，我们计算 $\mathbf{H}^T \mathbf{W}^{-1} \mathbf{z}$ 计算为：

其中， r_i 为中间变量。

3.3.2 通过MAP推导卡尔曼滤波

讲解如何将上一节的前向估计转换为递归滤波器(卡尔曼滤波器的形式)。假设我们现在已经有了k-1时刻的前向估计：

$$\{\hat{\mathbf{x}}_{k-1}, \hat{P}_{k-1}\}$$

我们要计算：

$$\{\hat{\mathbf{x}}_k, \hat{P}_k\}$$

其实，我们无需从头开始，只需要使用k-1时刻的状态以及k时刻的 \mathbf{v}_k (输入)， \mathbf{y}_k (观测)来估计k时刻的状态：

$$\{\hat{\mathbf{x}}_{k-1}, \hat{P}_{k-1}, \mathbf{v}_k, \mathbf{y}_k\} \rightarrow \{\hat{\mathbf{x}}_k, \hat{P}_k\}$$

因此，我们直接写出k-1时刻的估计与k时刻估计的关系：

$$\underbrace{\underbrace{\hat{\mathbf{x}}'_{k-1}}_{\hat{\mathbf{x}}_{k-1}}, \mathbf{y}_0, \mathbf{v}_1, \mathbf{y}_1, \mathbf{v}_2, \mathbf{y}_2, \dots, \mathbf{v}_{k-1}, \mathbf{y}_{k-1}, \mathbf{v}_k, \mathbf{y}_k, \mathbf{v}_{k+1}, \mathbf{y}_{k+1}, \dots, \mathbf{v}_K, \mathbf{y}_K}_{\hat{\mathbf{x}}_k}$$

我们定义：

$$\hat{x} = \begin{bmatrix} \hat{x}'_{k-1} \\ \hat{x}_k \end{bmatrix}$$

其中， \hat{x}'_{k-1} 是指利用了 v_k 和 y_k 估计得到的(利用了未来信息)。

3.3.3 通过贝叶斯推断推导卡尔曼滤波

设 $k-1$ 时刻的高斯先验为：

$$p(x_{k-1} | \check{x}_0, v_{1:k-1}, y_{0:k-1}) = N(\hat{x}_{k-1}, \hat{P}_{k-1})$$

首先，**对于预测部分**，我们考虑最近时刻的输入 v_k ，来计算 k 时刻的"先验"：

$$p(x_k | \check{x}_0, v_{1:k}, y_{0:k-1}) = N(\check{x}_k, \check{P}_k)$$

其中：

$$\begin{aligned} \check{P}_k &= A_{k-1} \hat{P}_{k-1} A_{k-1}^T + Q_k \\ \check{x}_k &= A_{k-1} \hat{x}_{k-1} + v_k \end{aligned}$$

我们简单对上述两式进行一下推导：

$$\begin{aligned} \check{P}_k (\text{根据方差定义}) &= E[(x_k - E[x_k])(x_k - E[x_k])^T] \\ &= E[(A_{k-1}x_{k-1} + v_k + w_k - A_{k-1}\hat{x}_{k-1} - v_k)(A_{k-1}x_{k-1} + v_k + w_k - A_{k-1}\hat{x}_{k-1} - v_k)^T] \\ &= A_{k-1}E[(x_{k-1} - \hat{x}_{k-1})(x_{k-1} - \hat{x}_{k-1})^T]A_{k-1}^T + E[w_k w_k^T] + E[w_k \times X] \\ &\quad (\text{矩阵 } X \text{ 为由 } x_k \text{ 分量组成的随机变量矩阵，与 } w_k \text{ 不相关}) \\ &= \dots + E[w_k]E[X] = \dots + 0 \\ &= A_{k-1}\hat{P}_{k-1}A_{k-1}^T + Q_k \end{aligned}$$

之后，**对于更新部分(测量)**，我们将状态与最近的依次测量写成联合高斯分布的形式：

$$\begin{aligned} p(x_k, y_k | \check{x}_0, v_{1:k}, y_{0:k-1}) &= \mathcal{N}\left(\begin{bmatrix} \mu_x \\ \mu_y \end{bmatrix}, \begin{bmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{bmatrix}\right) \\ &= \mathcal{N}\left(\begin{bmatrix} \check{x}_k \\ C_k \check{x}_k \end{bmatrix}, \begin{bmatrix} \check{P}_k & \check{P}_k C_k^T \\ C_k \check{P}_k & C_k \check{P}_k C_k^T + R_k \end{bmatrix}\right) \end{aligned} \quad (3.126)$$

根据2.2.3节，我们总能将 $p(x,y)$ 写成 $p(x|y)p(y)$

其中：

$$p(x, y) = p(x|y)p(y) \quad (2.53a)$$

$$p(x|y) = \mathcal{N}(\mu_x + \Sigma_{xy}\Sigma_{yy}^{-1}(y - \mu_y), \Sigma_{xx} - \Sigma_{xy}\Sigma_{yy}^{-1}\Sigma_{yx}) \quad (2.53b)$$

$$p(y) = \mathcal{N}(\mu_y, \Sigma_{yy}) \quad (2.53c)$$

根据上述推断，我们直接得到 x_k 的条件分布，即后验概率(上式把 y_k 拿到了后面)：

$$p(x_k | \check{x}_0, v_{1:k}, y_{0:k}) = \mathcal{N}\left(\underbrace{\mu_x + \Sigma_{xy}\Sigma_{yy}^{-1}(y_k - \mu_y)}_{\hat{x}_k}, \underbrace{\Sigma_{xx} - \Sigma_{xy}\Sigma_{yy}^{-1}\Sigma_{yx}}_{\hat{P}_k}\right) \quad (3.127)$$

此处，我们定义 \hat{x}_k 为均值， \hat{P}_k 为方差，代入之前的结果则有：

$$K_k = \check{P}_k C_k^T (C_k \check{P}_k C_k^T + R_k)^{-1} \quad (3.128a)$$

$$\hat{P}_k = (1 - K_k C_k) \check{P}_k \quad (3.128b)$$

$$\hat{x}_k = \check{x}_k + K_k (y_k - C_k \check{x}_k) \quad (3.128c)$$

3.3.4 从增益最优化的角度来看卡尔曼滤波

我们通常说**卡尔曼滤波是最优的**。同时，我们也确实从MAP中推导出了卡尔曼滤波与递归形式优化之间的关系。现从增益最优化的角度来看卡尔曼滤波。

假设一个估计器：

$$\hat{x}_k = \check{x}_k + K_k (y_k - C_k \check{x}_k)$$

但此时**不知道如何选取K的值**，我们定义状态误差为：

$$\hat{e}_k = \hat{x}_k - x_k$$

则有：

$$E[\hat{e}_k \hat{e}_k^T] = (1 - K_k C_k) \check{P}_k (1 - K_k C_k)^T + K_k R_k K_k^T$$

解释：协方差估计，第二项是，测量Y噪声带来的协方差。

我们定义出一个**代价函数**：

$$J(K_k) = \frac{1}{2} \text{tr} E[\hat{e}_k \hat{e}_k^T] = E[\frac{1}{2} \hat{e}_k^T \hat{e}_k]$$

使这个误差最小化，求Kk即可。

因此，对K求导得到：

$$\begin{aligned} \text{前置公式: } \frac{\partial \text{tr} XY}{\partial X} &= Y^T, \frac{\partial \text{tr} XZX^T}{\partial X} = 2XZ \\ \frac{\partial J(K_k)}{\partial K_k} &= -(1 - K_k C_k) \check{P}_k C_k^T + K_k R_k \end{aligned}$$

令偏导数=0即可求得：

$$K_k = \check{P}_k C_k^T (C_k \check{P}_k C_k^T + R_k)^{-1}$$

这就是卡尔曼增益的通常表达式。

3.3.5 关于卡尔曼滤波的讨论

以下是卡尔曼滤波的要点：

1. 对于高斯噪声的线性系统，卡尔曼滤波是**最优线性无偏估计**。这意味着它给出的解的协方差位于克拉美罗下界处。
2. 必须有初始状态 x_0 P0
3. 协方差部分与均值部分可以独立地递推，有时可以计算一个固定的Kk，用于所有时刻的均值修正。这种做法称为**固定状态的卡尔曼滤波**。
4. 实现当中我们用实际的传感器读数， y_k, meas
5. 从后向过程一样可以推导处类似的滤波方法，这种方法会沿着时间反向传递。

非线性场合下，我们需要使用——**扩展卡尔曼滤波器EKF**。

3.3.6 误差动态过程

3.3.7 存在性，唯一性以及能观性

3.4 连续时间的批量估计问题

3.4.1 高斯过程回归

3.4.2 一种稀疏的高斯过程先验

3.4.3 线性时不变情况

3.4.4 与批量离散时间情况的关系